

Taller Corte 1 Semana 3: Ingeniería de Datos

Universidad Católica de Colombia

Programa de Ingeniería de Sistemas y Computación

Estudiante: Daniel Felipe Gonzalez Rodriguez, Juan Sebastian Lozano Calderon

Docente: Diego Oliveros

Agosto 2026

Componente 2. Investigación Aplicada

1. Viaje del Dato y Arquitectura por Capas

En el contexto de la Ingeniería de Datos, el viaje del dato no se limita a mover archivos, sino a diseñar procesos trazables y confiables. La arquitectura propuesta para la plataforma de arrendamiento y venta de vehículos se divide en tres capas fundamentales:

- Capa RAW (Zona Cruda): Almacena los archivos originales (CSV) extraídos de Kaggle sin ninguna alteración. Su función es preservar la verdad absoluta del dato, garantizando que ante cualquier falla en el pipeline, la información original pueda recuperarse.
- Capa STAGING (Zona de Preparación): En esta zona temporal, los datos son perfilados, limpiados y transformados mediante scripts de Python y la librería Pandas. Aquí se resuelven problemas de nulos, formatos de fecha y duplicados antes de moverlos.
- Capa Analítica: Los datos ya procesados se cargan en una base de datos relacional (PostgreSQL), estructurados en un modelo dimensional listo para ser consultado por los consumidores de la información.

2. Contrato de Datos, Diccionario y Calidad

A diferencia de un simple diccionario de datos (que solo describe qué significa cada columna), un contrato de datos establece las reglas estructurales que el dato debe cumplir para no corromper el sistema. Las dimensiones de calidad aplicadas son:

- Completitud: Campos críticos como la marca y el precio no pueden tener valores nulos.
- Validez y Consistencia: Los valores numéricos (kilometraje, precio) no pueden ser negativos, y las fechas deben mantener un formato ISO estandarizado.

3. Grano, Hechos y Dimensiones

El modelo dimensional abandona la lógica transaccional clásica para enfocarse en el análisis de negocio. Para este proyecto:

- Grano: La unidad de análisis (el nivel de detalle más bajo) se define como: "Una fila representa el registro individual de un vehículo disponible o vendido en una ubicación y fecha determinada".
- Hechos: Las métricas cuantitativas que se van a medir, tales como el precio (price/sale price), el kilometraje (odometer/mileage) y las tasas de comisión.
- Dimensiones: El contexto de los hechos. Incluye la dimensión Vehículo (marca, modelo, año, transmisión), Ubicación (región, latitud, longitud) y Tiempo (fecha de publicación).

4. Fuentes Técnicas Consultadas (Normas APA)

- Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). Wiley.
- The PostgreSQL Global Development Group. (2026). PostgreSQL Documentation. <https://www.postgresql.org/docs/>
- Pandas Development Team. (2026). Pandas Documentation. <https://pandas.pydata.org/docs/>

Componente 3. Avance del Proyecto Integrador

1. Definición del Problema y Dominio

Problema: El mercado de arrendamiento y venta de vehículos genera un alto volumen de información dispersa en diferentes formatos. Existe la necesidad de analizar tendencias de precios y características vehiculares unificando múltiples fuentes (ej. ventas locales, internacionales y registros de Craigslist).

Consumidor: Analistas de mercado y sistemas de tableros de control (Dashboards) que requieren la información centralizada y limpia para la toma de decisiones estratégicas de precios.

2. Mapa del Viaje del Dato y Diagnóstico RAW

Para la extracción, se obtienen los datasets en formato CSV desde Kaggle ("car sales ETL", "used cars dataset", "Car Sales"). Estos archivos ingresan directamente a la capa RAW. A continuación, se detalla el Contrato de Datos Unificado que se aplicará en la capa STAGING:

Campo Unificado	Origen (Fuentes)	Tipo	Obligatorio	Regla Validación	Acción (Error)
precio	price, sale price	Numérico	Sí	Mayor a 0	Rechazar registro
marca	brand, manufacturer	Texto	Sí	No nulo	Rechazar registro
kilometraje	odometer, mileage	Numérico	No	Mayor o igual a 0	Imputar nulo
fecha	date, posting_date	Fecha	Sí	Formato YYYY-MM-DD	Enviar a revisión
estado	condition	Texto	No	Lista de valores	Dejar en blanco

3. Script de Perfilamiento RAW (Ejecución en Python/Colab)

El siguiente script evidencia el perfilamiento inicial de las fuentes. Se ejecuta en la capa RAW para conocer el estado de la información sin alterarla, cumpliendo con la preservación del dato original.

```
import pandas as pd

# 1. Carga de los archivos en la capa RAW (Reemplazar con rutas de Colab)
# df_car_sales_etl = pd.read_csv('car_sales_etl.csv')
# df_used_cars = pd.read_csv('used_cars.csv')
# df_car_sales = pd.read_csv('car_sales.csv')

# Ejemplo de diagnóstico usando uno de los datasets cargados:
df = pd.read_csv('car_sales.csv')

print("--- DIAGNÓSTICO BÁSICO CAPA RAW ---")
print(f"Total de filas y columnas: {df.shape}\n")

print("--- Conteo de valores nulos por columna ---")
print(df.isnull().sum())


print("\n--- Total de filas duplicadas exactas ---")
print(df.duplicated().sum())

print("\n--- Tipos de datos detectados (Inferidos) ---")
print(df.dtypes)
```

4. Riesgos y Tareas Pendientes

- **Riesgo de Calidad:** Los formatos de fecha (date, posting_date) pueden diferir sustancialmente entre los tres datasets de Kaggle. Será necesario unificarlos en STAGING.
- **Tarea Pendiente (Semana 4-5):** Implementar las reglas de limpieza definidas en el contrato de datos utilizando Pandas y exportar el resultado estructurado para preparar la ingesta a la base de datos PostgreSQL.

5. Modelo en estrella:



dim_ubicacion	
id_ubicacion	int
region	varchar
estado_provincia	varchar
ciudad_localidad	varchar
latitud	float
longitud	float

dim_comercial	
id_comercial	int
vendedor	varchar
cliente	varchar

fact_eventos_vehiculos	
id_evento	int
id_vehiculo	int
id_tiempo	int
id_ubicacion	int
id_comercial	int
precio	float
kilometraje	float
tasa_comision	float
comision_ganada	float

dim_vehiculo	
id_vehiculo	int
marca	varchar
modelo	varchar
anio_fabricacion	int
estado_condicion	varchar
tipo_combustible	varchar
transmision	varchar
tipo_carroceria	varchar
color	varchar
cilindros	varchar

dim_tiempo	
id_tiempo	int
fecha_completa	date
anio	int
mes	int
dia_semana	varchar
trimestre	varchar